

Homework 2: Embeddings

- א. עליך לבחור סוג אחד של מקור לטקסטים מבין הסוגים הבאים:
- טקסט מווטסאפ או מרשת חברתית
 - טקסט מוויקיפדיה
 - נאומים (מתרגיל 1)
 - כתבה חדשותית (מ YNET, למשל)
 - סיפור קצר
- עבור הסוג שבחרת עליך למצוא 5 טקסטים שונים אשר כל אחד מהם הינו באורך של 300 מילים לפחות.
- ב. באמצעות מודל שפה (למשל CLAUDE), ייצר 5 טקסטים נוספים מאותו הסוג שבחרת בסעיף הקודם. בפרומפט שישלח למודל השפה עליך לבקש שהוא ישתמש באוצר מילים מצומצם ככל הניתן ליצירת הטקסטים הללו.
- ג. עליך לייצג כל מילה בכל אחד מ 10 הטקסטים באמצעות 4 שיטות שונות:
- Bag of Words
 - TF-IDF
 - Word2Vec / FastText / GloVe (ניתן להשתמש במודל מוכן, או לאמן מודל קטן באמצעות ספריית gensim)
 - sentence-transformers/all-MiniLM-L6-v2 / BERT / MiniLm / DistilBERT
- ד. עליך לחזור על סעיף ג' פעמיים עבור אורכי EMBEDDINGS שונים: 30, ו - 300. כלומר, בסוף התהליך יהיו 16 מודלי EMBEDDINGS שונים (4 שיטות 2×2 גדלים $2 \times$ סוגי טקסטים [הטקסט המקורי והטקסטים שג'ונרטו באמצעות מודל ה AI])
- מסעיף ה' עד סעיף ז' – נבצע מחקר השוואתי של 3 שאלות מחקר. עליכם לבחור את המתודולוגיה לבחינת שאלות המחקר הללו.
- ה. עליך לבחור 2 מבין שאלות המחקר המצוינות להלן, ולהגדיר ניסוי שיבחן אותה, בהתבסס על מה שיצרת עד עכשיו ודאטה נוסף ככל שיידרש.
- איזו שיטה מזהה טוב יותר טקסטים דומים?
 - איזו שיטה מפרידה טוב יותר בין טקסטים שונים?
 - איזו שיטה רגישה יותר למילים משותפות?
 - איזו שיטה מזהה דמיון סמנטי גם כשאין חפיפה מילולית?
- ו. כיצד אורך ה EMBEDDING משפיע על איכות התוצאות. הצג את תוצאות ההשוואה בטבלה.
- ז. נסו להקטין את ה EMBEDDING באורך 300 ל EMBEDDING באורך 30 באמצעות PCA. השוו את התוצאות של ההשוואות בסעיף ה' בין 2 ה EMBEDDINGS באורך 30. תארו את התוצאות והמסקנות.
- ח. בחרו 3 משפטים מתוך הדאטה שיצרתם וחשבו עבורם באופן ידני (הציגו את השלבים השונים) וקטור BOW, ווקטור IDF-TF. חשבו SIMILARITY_COSINE בין 3 זוגות מילים בכל אחד מהקידודים.

ייתכן והסעיפים הבאים יעזרו לענות על הסעיפים הקודמים. אין צורך לענות על הסעיפים הללו באם הם אינם מסייעים במתן תשובה לסעיפים הקודמים.

ט. עליך להמציא בעצמכם קבוצת טקסטים קטנה שמטרתה להראות הבדל גדול בין שיטות embedding.

תוכל להיעזר במשפטים הבאים:

דוגמה ל 3 משפטים בעלי משמעות דומה אך עם מילים שונות:

A: The doctor treated the patient.

B: The physician helped the sick person.

C: Medical care was provided to the injured man.

דוגמה ל 3 משפטים עם מילים דומות אך משמעות שונה:

D: The bank approved the loan.

E: The fisherman sat on the bank.

F: The river bank was full of stones.

חשב embeddings למשפטים האלה ולבדוק:

- איזו שיטה מזהה טוב יותר דמיון סמנטי?
 - איזו שיטה מתבלבלת בגלל חפיפה מילולית?
 - באיזה זוג משפטים ההבדל בין השיטות הוא הגדול ביותר?
 - מדוע לדעתכם התקבל ההבדל הזה?
- י. מדוע TF-IDF עלול להיכשל בזיהוי דמיון סמנטי בין שני משפטים?
- יא. האם embedding בעל מימד גבוה יותר תמיד נותן תוצאה טובה יותר? נמק על בסיס הניסוי שלכם. מה עלול לקרות כאשר מימד ה- embedding קטן מדי? הדגם